

# Modelos matemáticos Capítulo 1 Robert P. Dobrow

(Intro a los P. Estocásticos con R)

## Ley de Probabilidad Total

$$P(A) = \sum_{i=1}^k P(A \cap B_i) = \sum_{i=1}^k P(A|B_i)P(B_i)$$

$B_i$  son mutuamente excluyentes y su unión es igual a  $\Omega$ .

## Regla de Bayes

$$P(B|A) = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|B^c)P(B^c)}$$

Más general...

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_j P(A|B_j)P(B_j)}$$

## Distribución Condicional

### Caso discreto

$$P(Y=y|X=x) = \frac{P(X=x, Y=y)}{P(X=x)}$$

también conocida como la función de masa de probabilidad condicional, es una función de  $y$  con  $x$  fijo.

### Caso continuo

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$$

también conocida como la función de densidad condicional es una función de  $y$  donde  $x$  es fijo.

Las densidades condicionales sirven para calcular probabilidades condicionales de la siguiente manera

$$P(Y \in R | X=x) = \int_R f_{Y|X}(y|x) dy ; R \subseteq \mathbb{R}$$

## Esperanza Condicional de $Y$ dado $X=x$

$$E(Y|X=x) = \begin{cases} \sum_y y P(Y=y|X=x), & \text{para caso discreto} \\ \int_{-\infty}^{+\infty} y f_{Y|X}(y|x) dy, & \text{para caso continuo} \end{cases}$$

Donde  $E(Y|X=x)$  es una función de  $x$

## Propiedades Esperanza Condicional

1) Linealidad  $\rightarrow E(aY+bZ|X=x) = aE(Y|X=x) + bE(Z|X=x)$

2) Si  $g$  una función...

$$E(g(Y)|X=x) = \begin{cases} \sum_y g(y) P(Y=y|X=x), & \text{para caso discreto} \\ \int_{-\infty}^{+\infty} g(y) f_{Y|X}(y|x) dy, & \text{para caso continuo} \end{cases}$$

3) Independencia ( $X$  &  $Y$  independientes)

$$E(Y|X=x) = E(Y)$$

4) Si  $Y=g(X)$  una función de  $X$

$$E(Y|X=x) = g(x)$$

## Ley de Esperanza Total

$$E(Y) = \sum_{i=1}^k E(Y|A_i)P(A_i)$$

$A_i$  son eventos que particionan a  $\Omega$

⚠ Si  $X$  &  $Y$  están conjuntamente distribuidas

$$E(Y) = \sum_x E(Y|X=x)P(X=x)$$

## Esperanza Condicional de $Y$ dado $X$

$E(Y|X)$  tiene 3 propiedades definitorias

- 1)  $E(Y|X)$  resulta ser una variable aleatoria
- 2)  $E(Y|X)$  es una función de  $X$
- 3)  $E(Y|X) = E(Y|X=x)$  siempre que  $X=x$ . Esto puede ser visto de otra forma como:

$$\left[ \begin{array}{l} \text{Si } E(Y|X=x) = g(x) \quad \forall x, \\ \text{Entonces } E(Y|X) = g(X) \end{array} \right.$$

## Suma Aleatoria de Variables Aleatorias

$$T = X_1 + \dots + X_N = \sum_{k=1}^N X_k$$

Donde  $X_1, X_2, \dots$  es una secuencia i.i.d con media  $\mu$ , y  $N$  es una var. aleatoria con media  $\lambda$ .

## Esperanza de suma aleatoria de var. aleatorias.

Se tiene que

$$\rightarrow E(T|N=n) = n\mu$$

$$\left[ \begin{array}{l} \text{y como } \forall n \text{ se cumple } E(T|N=n), \\ \text{entonces } E(T|N) = N\mu \end{array} \right.$$

Ahora por ley de esperanza total \*

$$E(T) = E(E(T|N)) = E(N\mu) = \mu E(N) = \mu \lambda$$

## Varianza Condicional

$$\text{Var}(Y|X=x) = E((Y - \mu_x)^2 | X=x)$$

$$= \begin{cases} \sum_y (y - \mu_x)^2 P(Y=y|X=x), & \text{para caso discreto} \\ \int_{-\infty}^{+\infty} (y - \mu_x)^2 f_{Y|X}(y|x) dy, & \text{para caso continuo} \end{cases}$$

$$\text{donde } \mu_x = E(Y|X=x)$$

## Propiedades de la Varianza Condicional

$$1) \text{Var}(Y|X=x) = E(Y^2|X=x) - (E(Y|X=x))^2$$

$$2) \text{Var}(aY+b|X=x) = a^2 \text{Var}(Y|X=x)$$

## Ley de la Varianza Total

$$\text{Var}(Y) = E(\text{Var}(Y|X)) + \text{Var}(E(Y|X))$$

## Varianza de suma aleatoria de variables aleatorias

Considere que la secuencia  $X_1, X_2, \dots$  es i.i.d y tiene media  $\mu_X$  y varianza  $\sigma_X^2$ .

Además  $N$  una var. aleatoria con media  $\mu_N$  y varianza  $\sigma_N^2$ ; donde  $N$  es independiente de cada  $X_i$ .

Donde  $T = X_1 + \dots + X_N$

$$\text{Var}(T) = E(\text{Var}(T|N)) + \text{Var}(E(T|N))$$

$$= E(N\sigma_X^2) + \text{Var}(N\mu_X)$$

$$= \sigma_X^2 E(N) + \mu_X \text{Var}(N)$$

$$= \sigma_X^2 \mu_N + \mu_X \sigma_N^2$$

## Generalizando y conjuntando los resultados de esperanza y varianza de sumas aleatorias de variables aleatorias. Sean

- $X_1, X_2, \dots$  secuencia i.i.d. con media común  $\mu_X$  y varianza  $\sigma_X^2$
- $N$  una var. aleatoria positiva entero valuada independiente de cada  $X_i$ , y con media  $\mu_N$  y varianza  $\sigma_N^2$
- $T = \sum_{i=1}^N X_i$

Se tiene que

$$E(T) = \mu_X \mu_N$$

$$\text{Var}(T) = \sigma_X^2 \mu_N + \sigma_N^2 \mu_X$$



# Modelos matemáticos Capítulo 2 Robert P. Dobrow

(Intro a los P. Estocásticos con R)

## Cadena de Markov (Definición):

Una cadena de Markov es una secuencia de variables aleatorias  $X_0, X_1, \dots$  que toma valores de el conjunto de estados discreto  $S$ , teniendo la propiedad de que

$$P(X_{n+1}=j | X_0=x_0, \dots, X_{n-1}=x_{n-1}, X_n=x_n) = P(X_{n+1}=j | X_n=i)$$

para todo  $x_0, \dots, x_{n-1}; i, j \in S; n \geq 0$

## Homogeneidad del tiempo

A menos que se diga lo contrario, se asume que una cadena de Markov es homogénea en el tiempo lo cual genera que

$$P(X_{n+1}=j | X_n=i) = P(X_1=j | X_0=i)$$

## Matriz de transición de n-pasos

Sea  $X_0, X_1, \dots$  una cadena de Markov con matriz de transición  $P$ . La matriz  $P^n$  es la matriz de transición de  $n$ -pasos de dicha cadena, si para  $n \geq 0$

$$P_{ij}^n = P(X_n=j | X_0=i) \quad \forall i, j$$

⚠ Nota:  $P^0$  es la matriz identidad

## Distribución inicial

Para una cadena de Markov  $X_0, X_1, \dots$  la distribución de  $X_0$  es la distribución inicial denotada por  $\alpha = (\alpha_1, \alpha_2, \dots)$ . Donde  $P(X_0=j) = \alpha_j \quad \forall j$

## Distribución de $X_n$

Sea la cadena de Markov  $X_0, X_1, \dots$  con matriz de transición  $P$  y distribución inicial  $\alpha$ . Donde para  $n \geq 0$ , la distribución de  $X_n$  es  $\alpha P^n$ . Esto es

$$P(X_n=j) = (\alpha P^n)_j \quad \forall j$$

## Propiedad de Markov

Sea  $X_0, X_1, \dots$  una cadena de Markov. Por lo que para todo  $m < n$  se cumple

$$\begin{aligned} & P(X_{n+1}=j \mid X_0=i_0, \dots, X_{n-m-1}=i_{n-m-1}, X_{n-m}=i) \\ &= P(X_{n+1}=j \mid X_{n-m}=i) \\ &= P(X_{m+1}=j \mid X_0=i) = P_{ij}^{m+1} \end{aligned}$$

esto para todo  $i, j, i_0, \dots, i_{n-m-1}$  y  $n \geq 0$

## Distribución conjunta

Sea  $X_0, X_1, \dots$  una cadena de Markov con matriz de transición  $P$  y distribución inicial  $\alpha$ .

Para todo  $0 \leq n_1 < n_2 < \dots < n_{k-1} < n_k$  y estados  $i_1, i_2, \dots, i_{k-1}, i_k$

$$\begin{aligned} & P(X_{n_1}=i_1, X_{n_2}=i_2, \dots, X_{n_{k-1}}=i_{k-1}, X_{n_k}=i_k) \\ &= (\alpha P^{n_1})_{i_1} (P^{n_2-n_1})_{i_1 i_2} \dots (P^{n_k-n_{k-1}})_{i_{k-1} i_k} \end{aligned}$$

# Distribuciones útiles para los ejercicios Capítulos 1 y 2 Dobrow

## Distribución binomial

$$X \sim \text{Bin}(n, p)$$

$$P(X=x) = \binom{n}{x} p^x (1-p)^{n-x}$$

$$E(X) = np, \text{Var}(X) = np(1-p)$$

Modela el número de éxitos en una secuencia de  $n$  ensayos Bernoulli independientes entre sí, con una probabilidad fija  $p$  de ocurrencia de éxito.

## Distribución Geométrica

$$X \sim \text{Geo}(p)$$

$$P(X=x) = p(1-p)^{x-1}$$

$$E(X) = \frac{1}{p}, \text{Var}(X) = \frac{1-p}{p^2}$$

Modela el número de fracasos antes de obtener el primer éxito en una sucesión de ensayos Bernoulli independientes entre sí, con una probabilidad fija  $p$  de ocurrencia de éxito.

## Distribución Uniforme Continua

$$X \sim U(a, b) \sim \text{Unif}(a, b)$$

$$f_X(x) = \frac{1}{b-a}$$

$$E(X) = \frac{a+b}{2}, \text{Var}(X) = \frac{(b-a)^2}{12}$$

Modela cuando una variable aleatoria posee la misma probabilidad constante sobre el intervalo  $(a, b)$

## Distribución Poisson

$$X \sim \text{Poisson}(\lambda)$$

$$P(X=x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

$$E(X) = \lambda, \text{Var}(X) = \lambda$$

Modela la ocurrencia de un determinado número de eventos durante cierto periodo de tiempo, esto a partir de una frecuencia de ocurrencia media  $\lambda$ .